Entrega 2 - Econometría Aplicada

Miguel Fernández Vicente

March 5, 2026

1 Ejercicio 1

1.1 Enunciado

El objetivo es estudiar la relación entre el nivel educativo y los ingresos mensuales de los individuos, basándonos en la teoría del Capital Humano. Para ello se utiliza el fichero `wage2` y se estima la relación entre:

- *wage*: ingresos (salario) mensual.
- *educ*: años de educación.

Dado que es plausible que la educación sea endógena, se plantea el uso de variables instrumentales. En particular, se consideran como instrumentos: *sibs* (número de hermanos) y *meduc* (educación de la madre), y posteriormente se incorpora *exper* (experiencia laboral) como variable exógena de control.

1.2 Resolución

1) Modelo base por MCO. Como punto de partida se estima por MCO:

$$wage_i = \beta_0 + \beta_1\, educ_i + u_i. \tag{1}$$

La estimación arroja:

$$\widehat{wage}_i = 146.952 + 60.214\, educ_i,$$

donde el coeficiente de educación es positivo y altamente significativo ($p < 2 \times 10^{-16}$). La interpretación es directa: **un año adicional de educación se asocia, en promedio, con un aumento de aproximadamente 60.2 unidades monetarias en el salario mensual**. El ajuste del modelo es moderado ($R^2 = 0.107$), lo cual es habitual en datos microeconómicos.

2) Motivación: posible endogeneidad de *educ*. Es razonable sospechar que $\mathrm{Cov}(educ_i, u_i) \neq 0$ por variables omitidas (habilidad innata, motivación, entorno familiar, etc.) que afectan tanto a educación como a salario. En ese caso, MCO sería inconsistente y se recurre a Mínimos Cuadrados Bietápicos (MC2E), buscando instrumentos que cumplan:

- **Relevancia**: el instrumento debe estar correlacionado con *educ*.
- **Exogeneidad**: el instrumento no debe estar correlacionado con el error de la ecuación salarial.

3) MC2E con un instrumento: *sibs*. Se propone *sibs* (número de hermanos) como instrumento. La primera etapa es:

$$educ_i = \pi_0 + \pi_1\, sibs_i + v_i. \tag{2}$$

El instrumento es relevante: $\widehat{\pi}_1 = -0.2279$ y es significativo ($p = 1.22 \times 10^{-13}$). Además, el diagnóstico de instrumentos débiles reporta un estadístico 56.667 (regla práctica: $F > 10$), por lo que no hay evidencia de instrumento débil.

La segunda etapa (2SLS) ofrece:

$$\widehat{\beta}_1^{IV} = 122.47 \quad (p = 1.48 \times 10^{-6}),$$

un retorno a la educación más alto que en MCO. Para contrastar si realmente existe endogeneidad, se utiliza el test de Wu–Hausman. Se obtiene p-valor = 0.00699, por lo que **se rechaza la exogeneidad de *educ*** y, en consecuencia, se prefiere MC2E frente a MCO para inferencia causal. En este caso no puede aplicarse Sargan (modelo exactamente identificado).

4) MC2E con dos instrumentos: *sibs* y *meduc*. Se amplía el conjunto instrumental incorporando *meduc*. La primera etapa:

$$educ_i = \pi_0 + \pi_1\, sibs_i + \pi_2\, meduc_i + v_i, \tag{3}$$

muestra que ambos instrumentos son significativos y el diagnóstico de instrumentos débiles es sólido (estadístico 76.433). La estimación IV resulta:

$$\widehat{\beta}_1^{IV} = 112.98 \quad (p = 3.59 \times 10^{-12}).$$

El test de Wu–Hausman vuelve a rechazar exogeneidad (p-valor = 0.000236), reforzando la idea de que MCO es inconsistente. Además, al estar el modelo sobreidentificado, puede aplicarse el test de Sargan: el p-valor es 0.546, por lo que **no se rechaza la validez conjunta de los instrumentos**. (Este test no prueba validez, pero sí ausencia de evidencia contra la restricción de exclusión.)

5) Incorporando experiencia laboral (*exper*) como control. Para mejorar la especificación se incluye *exper* como variable exógena:

$$wage_i = \beta_0 + \beta_1\, educ_i + \beta_2\, exper_i + u_i. \tag{4}$$

Por MCO se obtiene que tanto educación ($\widehat{\beta}_1 = 76.216$) como experiencia ($\widehat{\beta}_2 = 17.638$) son significativas.

En el enfoque IV, las variables exógenas se instrumentan a sí mismas. Por tanto, el modelo 2SLS queda:

$$wage \sim educ + exper \;\;\big|\;\; sibs + meduc + exper.$$

La estimación proporciona:

$$\widehat{\beta}_1^{IV} = 141.64 \quad (p = 7.33 \times 10^{-13}), \qquad \widehat{\beta}_2^{IV} = 34.20 \quad (p = 1.27 \times 10^{-9}).$$

Los instrumentos siguen siendo fuertes (estadístico 62.415) y el test de Wu–Hausman rechaza exogeneidad (p-valor = 0.00022). El test de Sargan no rechaza (p-valor = 0.836), por lo que no hay evidencia contra la validez conjunta de los instrumentos.

Conclusión. En todas las especificaciones el retorno a la educación es positivo. Sin embargo, los tests de Wu–Hausman sugieren que *educ* es endógena, por lo que MCO sería inconsistente. Dado que los instrumentos considerados (*sibs* y *meduc*) resultan relevantes (no débiles) y no se rechaza su validez conjunta cuando procede (Sargan), el enfoque preferible para inferencia causal es el MC2E, especialmente en la especificación con controles (*exper*).

2 Ejercicio 2

2.1 Enunciado

Estudiar el efecto de la educación sobre la fertilidad utilizando el fichero `fertil2`. En particular, se analiza la relación entre:

- *children*: número de hijos (variable dependiente, de conteo).
- *educ*: años de educación.
- *age*: edad.

Se considera la posibilidad de endogeneidad de la educación y se proponen instrumentos como *frsthalf* (nacer en la primera mitad del año) y *urban* (grado de urbanización).

2.2 Resolución

El objetivo principal es cuantificar el efecto de la educación (*educ*) sobre la fertilidad (*children*), controlando por la edad. Dado que la fertilidad puede variar con la edad de forma no lineal, se incorpora un término cuadrático en la edad.

1) Exploración inicial. Como paso previo se representa *children* frente a *age*. Al tratarse de una variable de conteo, los puntos se agrupan en niveles enteros, pero se aprecia una relación creciente con posible curvatura. Esto justifica incluir age^2 en el modelo.

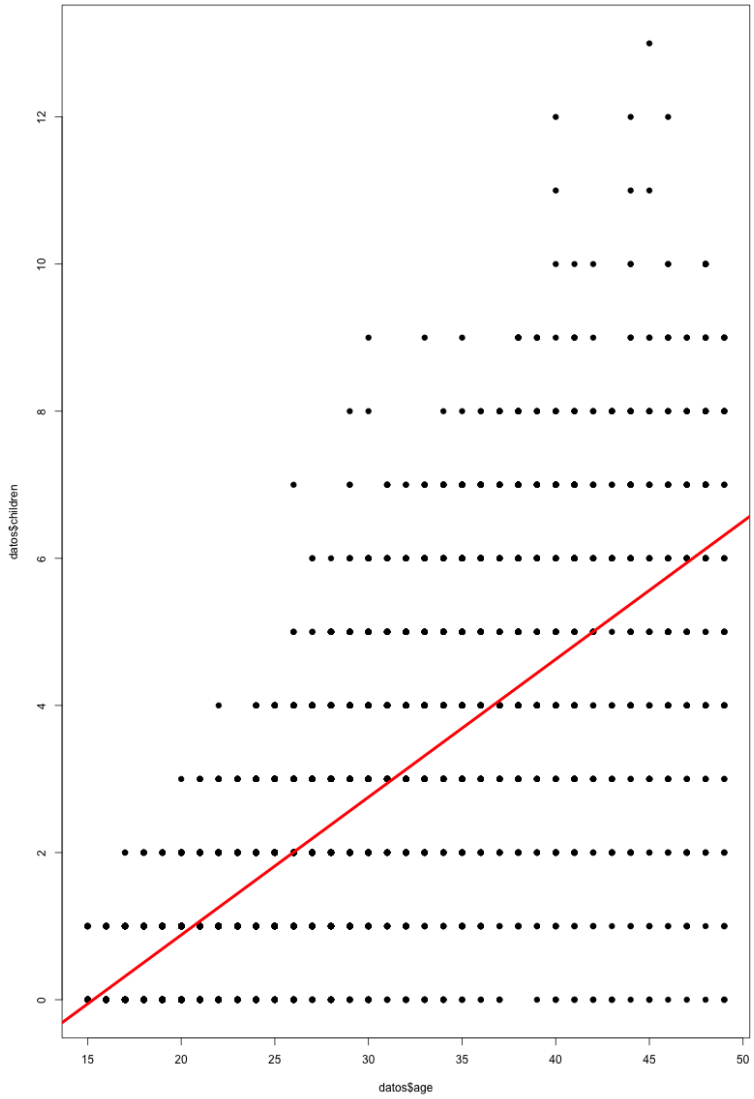


Figure 1: Dispersión de *children* frente a *age*. La forma sugiere incorporar un término cuadrático en la edad.

2) Estimación por MCO. Se plantea el modelo:

$$children_i = \beta_0 + \beta_1 educ_i + \beta_2 age_i + \beta_3 age_i^2 + u_i. \tag{5}$$

La estimación por MCO arroja:

$$\widehat{children}_i = -4.138 - 0.0906\, educ_i + 0.3324\, age_i - 0.002631\, age_i^2. \tag{6}$$

Los coeficientes son altamente significativos. En particular, el coeficiente de educación es negativo ($\widehat{\beta}_1 = -0.0906$), lo que indica que, **manteniendo constante la edad**, un año adicional de educación se asocia con una reducción media de aproximadamente 0.09 hijos. El modelo presenta un ajuste moderado-alto ($R^2 = 0.5687$).

3) Posible endogeneidad de la educación y motivación de IV. Desde un punto de vista económico, es plausible que *educ* esté correlacionada con el término de error: por ejemplo, preferencias, normas culturales o planes familiares pueden afectar simultáneamente a educación y fertilidad (variable omitida). Esto se expresa como $\text{Cov}(educ_i, u_i) \neq 0$, lo que sesgaría MCO. Para abordar esta posibilidad se recurre a variables instrumentales.

4) MC2E con un instrumento: *frsthalf*. Se utiliza *frsthalf* como instrumento bajo dos condiciones: (i) relevancia ($\text{Cov}(frsthalf, educ) \neq 0$) y (ii) exogeneidad (afecta a *children* solo a través de *educ*).

La primera etapa estimada es:

$$educ_i = \pi_0 + \pi_1 frsthalf_i + \pi_2 age_i + \pi_3 age_i^2 + v_i, \tag{7}$$

donde *frsthalf* es significativa ($\widehat{\pi}_1 = -0.852$, $p < 10^{-13}$). Además, el diagnóstico de instrumentos débiles en el 2SLS da un estadístico de 57.059 (con p-valor 5.12×10^{-14}), lo que indica que el instrumento es relevante (regla práctica: $F > 10$).

La estimación MC2E (2SLS) con un instrumento produce:

$$\widehat{educ} = -0.1715 \quad (p = 0.00127),$$

más negativo que en MCO. Sin embargo, el test de Wu–Hausman arroja p-valor $= 0.118$, por lo que **no se rechaza la exogeneidad** de *educ* a niveles habituales. Es decir, con este instrumento no hay evidencia suficiente para afirmar que MCO esté sesgado por endogeneidad (aunque la sospecha inicial fuese razonable).

5) MC2E con dos instrumentos: *frsthalf* y *urban*. Se amplía el conjunto instrumental incorporando *urban*. En la primera etapa ambos instrumentos resultan significativos y el contraste conjunto:

$$H_0 : frsthalf = 0 \text{ y } urban = 0$$

se rechaza con claridad (estadístico $F = 133.07$, $p < 2.2 \times 10^{-16}$), lo que indica instrumentos fuertes.

La estimación 2SLS con dos instrumentos da:

$$\widehat{\beta}_1 = -0.2233 \quad (p < 2 \times 10^{-16}),$$

un efecto más negativo que en MCO. Ahora el test de Wu–Hausman sí rechaza exogeneidad (p-valor $= 2.84 \times 10^{-8}$), lo que sugiere que **la educación es endógena** y que MCO estaría sesgado. Además, el test de sobreidentificación (Sargan) ofrece p-valor $= 0.284$, por lo que **no se rechaza** la validez conjunta de los instrumentos (esto no prueba que sean válidos, pero sí que son compatibles con las restricciones de exclusión).

Conclusión. En todas las especificaciones el efecto estimado de la educación sobre la fertilidad es negativo. Bajo MCO, un año adicional de educación reduce la fertilidad media en torno a 0.09 hijos. Al introducir instrumentos, el efecto estimado se vuelve más negativo (hasta -0.223 con

dos instrumentos). Los diagnósticos con dos instrumentos apuntan a endogeneidad de *educ* (Wu–Hausman significativo) y a instrumentos relevantes (estadístico elevado), sin evidencia en contra de su validez (Sargan no rechaza). Por tanto, en este ejercicio el modelo preferible para inferencia causal es el MC2E con dos instrumentos.

3 Ejercicio 3

3.1 Enunciado

Estudiar el efecto del consumo de tabaco de las madres durante el embarazo sobre el peso del bebé al nacer, utilizando el fichero `bwght`. En concreto, se considera:

- Variable dependiente: *lbwght* (logaritmo del peso del bebé al nacer).
- Variables explicativas: *packs* (paquetes fumados al día durante el embarazo), *male* (indicador de si el bebé es niño), *parity* (orden de nacimiento), *lfaminc* (logaritmo de los ingresos familiares).

Se discute la posible endogeneidad de *packs* y se prueban instrumentos como *cigprice* (precio del tabaco), *cigtax* (impuesto) y *motheduc* (educación de la madre).

3.2 Resolución

El objetivo es cuantificar el efecto del consumo de tabaco durante el embarazo (*packs*) sobre el peso del bebé al nacer (*lbwght*), controlando por variables demográficas y económicas. Se plantea el modelo lineal:

$$lbwght_i = \beta_0 + \beta_1 packs_i + \beta_2 male_i + \beta_3 parity_i + \beta_4 lfaminc_i + u_i. \tag{8}$$

La muestra disponible tiene tamaño $n = 1388$.

1) Estimación por MCO. La estimación por Mínimos Cuadrados Ordinarios produce:

$$\widehat{lbwght}_i = 4.6756 - 0.0837\, packs_i + 0.0262\, male_i + 0.0147\, parity_i + 0.0181\, lfaminc_i. \tag{9}$$

El coeficiente de *packs* es negativo y significativo ($\widehat{\beta}_1 = -0.0837$, $p = 1.12 \times 10^{-6}$). Como la variable dependiente está en logaritmos, la interpretación aproximada es porcentual: **un paquete adicional fumado al día durante el embarazo se asocia con una reducción de alrededor del** 8.4% **en el peso del bebé al nacer**, manteniendo constante el resto de variables. Los coeficientes de *male*, *parity* y *lfaminc* son positivos y significativos al 5%.

El ajuste del modelo es bajo ($R^2 = 0.035$), lo cual es habitual en regresiones individuales de resultados de salud, donde una gran parte de la variabilidad depende de factores no observados (salud materna, nutrición, genética, controles médicos, etc.).

2) Normalidad de residuos (diagnóstico). Se aplica el test de Jarque–Bera a los residuos de MCO, obteniendo un p-valor $< 2.2 \times 10^{-16}$, por lo que se rechaza la normalidad. Para visualizarlo, se representa el histograma de residuos (Figura 2). La no normalidad puede deberse a colas largas

o a la presencia de heterogeneidad no capturada; con $n = 1388$, la inferencia MCO suele apoyarse más en aproximaciones asintóticas que en normalidad exacta.

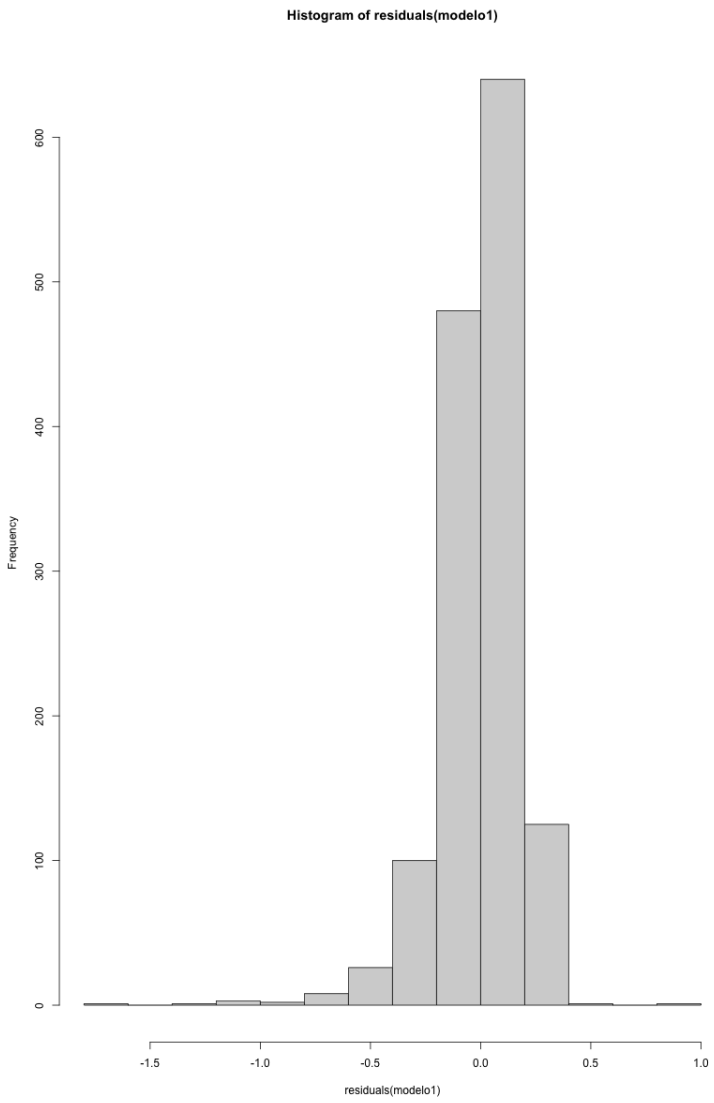


Figure 2: Histograma de residuos del modelo MCO. Se observan colas relativamente largas, coherentes con el rechazo de normalidad.

3) Posible endogeneidad de *packs* y estrategia de IV. Es razonable sospechar que $\mathrm{Cov}(packs_i, u_i) \neq 0$ debido a variables omitidas: por ejemplo, hábitos de salud generales de la madre, nutrición, estrés o acceso a controles médicos pueden estar correlacionados tanto con la decisión de fumar como con el peso al nacer. Para abordar esta posibilidad se intenta estimar por Mínimos Cuadrados Bietápicos (MC2E), buscando instrumentos relevantes y exógenos.

4) MC2E con *cigprice* como instrumento. Se propone el precio del tabaco (*cigprice*) como instrumento de *packs*. La segunda etapa estimada (2SLS) ofrece coeficientes muy imprecisos y un

cambio de signo en *packs* (no significativo). Lo relevante es el diagnóstico de instrumento débil: el test de "Weak instruments" tiene estadístico 1.002 con p-valor 0.317, indicando que *cigprice* no es un instrumento fuerte en esta muestra.

Esto se confirma en la primera etapa:

$$packs_i = \pi_0 + \pi_1 cigprice_i + \pi_2 male_i + \pi_3 parity_i + \pi_4 lfaminc_i + v_i, \tag{10}$$

donde *cigprice* no resulta significativo ($p = 0.317$). Por tanto, **no se cumple adecuadamente la condición de relevancia** y la aplicación de MC2E con este instrumento no es fiable.

5) Alternativas: *motheduc* y combinación *cigprice+cigtax*. Se prueba la educación de la madre (*motheduc*) como posible instrumento. En la primera etapa, *motheduc* sí aparece como predictor significativo de *packs* ($p = 3.05 \times 10^{-9}$) y el diagnóstico de instrumentos débiles mejora (estadístico 35.616, $p = 3.05 \times 10^{-9}$). Sin embargo, el test de Wu–Hausman en la estimación IV con *motheduc* arroja p-valor = 0.731, por lo que **no se rechaza la exogeneidad de *packs*** (en este modelo no hay evidencia estadística fuerte de que MCO esté sesgado por endogeneidad).

Adicionalmente, se prueban como instrumentos *cigprice* y *cigtax* conjuntamente. En la primera etapa ninguno resulta significativo individualmente y el contraste conjunto H_0 : *cigprice* = 0 y *cigtax* = 0 no se rechaza ($F = 0.7974$, $p = 0.4507$), lo que confirma que **ambos instrumentos son débiles** en esta muestra.

Conclusión. El modelo MCO sugiere un efecto negativo y estadísticamente significativo del consumo de tabaco durante el embarazo sobre el peso al nacer: un aumento de *packs* se asocia con un menor *lbwght*. La estrategia de variables instrumentales con *cigprice* (y con *cigprice+cigtax*) no es válida por instrumentos débiles. Con *motheduc* el instrumento es relevante, pero los diagnósticos (Wu–Hausman) no apoyan la necesidad de IV frente a MCO. En consecuencia, **el resultado de MCO debe interpretarse con cautela**, reconociendo la posible presencia de variables omitidas, y sin evidencia concluyente de que IV mejore la identificación causal con los instrumentos probados.