Métodos indirectos de estimación

Alicia Irusta Tejedor

23/04/2026

Índice

1 Objetivo de este documento **2**

2 Introducción **2**

2.1 Idea general 2

2.2 Parámetro, estadístico y estimador 3

3 Propiedades de los estimadores **4**

3.1 Esperanza matemática 4

3.2 Insesgadez 4

3.3 Sesgo 4

3.4 Varianza 4

3.5 Idea de compromiso 4

4 Determinación de estimadores lineales insesgados **5**

4.1 Forma de los parámetros del curso 5

5 Estimador de Hansen-Hurwitz **5**

5.1 Contexto 5

5.2 Varianza y su estimación 5

5.3 Ejercicio 1 6

6 Estimador de Horvitz-Thompson **8**

6.1 Contexto 8

6.2 Varianza y estimación 8

6.3 Ejercicio 2 8

7 Estimación indirecta **13**

7.1 Motivación 13

7.2 Supuestos del tema 13

8 Estimadores de razón **13**

8.1 Idea intuitiva . . . 13

8.2 Definiciones fundamentales . . . 13

8.3 Varianza aproximada . . . 14

8.4 Sesgo del estimador de razón . . . 14

8.5 Expresiones auxiliares . . . 15

9 Ejercicio 3: estimador de razón **15**

9.1 Paso 1. Calcular las medias muestrales . . . 15

9.2 Paso 2. Calcular la fracción de muestreo . . . 16

9.3 Paso 3. Calcular s_X^2 . . . 16

9.4 Paso 4. Calcular s_Y^2 . . . 16

9.5 Paso 5. Calcular s_{XY} . . . 16

9.6 Paso 6. Estimar la varianza de $\hat{R}$ . . . 17

9.7 Paso 7. Calcular el error de muestreo . . . 17

9.8 Paso 8. Aproximar el sesgo . . . 18

9.9 Paso 9. Estudiar la influencia del sesgo . . . 18

10 Ejercicio propuesto guiado **20**

10.1 Enunciado . . . 20

10.2 Sugerencias para resolverlo . . . 20

10.3 Solución resumida . . . 21

1 Objetivo de este documento

Este fichero resume y desarrolla **los métodos indirectos de estimación** presentados en clase de teoría.

En particular, se trabajan:

- la idea de **estimador** y de **parámetro poblacional**;
- las propiedades básicas de los estimadores: **esperanza**, **insesgadez**, **sesgo** y **varianza**;
- la construcción de estimadores lineales insesgados;
- el estimador de **Hansen-Hurwitz**;
- el estimador de **Horvitz-Thompson**;
- la **estimación indirecta** mediante **estimadores de razón**.

2 Introducción

2.1 Idea general

El objetivo de un estudio por muestreo es **inferir** características de una población a partir de la información contenida en una muestra.

Partimos de una población de tamaño N:

$$\Omega = \{u_1, u_2, \ldots, u_N\},$$

en la que se estudia una variable de interés X, cuyos valores poblacionales son

$$X(\Omega) = \{X_1, X_2, \ldots, X_N\}.$$

Seleccionamos una muestra de tamaño n:

$$M = \{u_1, u_2, \ldots, u_n\},$$

y observamos en ella los valores muestrales

$$x(M) = \{x_1, x_2, \ldots, x_n\}.$$

La idea central es que queremos estimar un **parámetro poblacional** a partir de los datos observados en la muestra.

2.2 Parámetro, estadístico y estimador

2.2.1 Parámetro

Un **parámetro** θ es una característica poblacional que queremos conocer. En este tema aparecerán sobre todo:

- **total poblacional**:
$$X = \sum_{i=1}^{N} X_i;$$
- **media poblacional**:
$$\bar{X} = \frac{1}{N} \sum_{i=1}^{N} X_i;$$
- **proporción poblacional**:
$$P = \frac{1}{N} \sum_{i=1}^{N} \delta_{u_i}.$$

2.2.2 Estadístico

Un **estadístico** es una función de las observaciones muestrales.

2.2.3 Estimador

Si ese estadístico se utiliza para aproximar un parámetro poblacional, lo llamamos **estimador**.

Así, un estimador de θ es cualquier función de la muestra,

$$\hat{T} = \hat{T}(M) = \hat{T}(u_1, u_2, \ldots, u_n).$$

Es importante recordar que $\hat{T}$ **es una variable aleatoria**, porque depende de la muestra elegida y la muestra se selecciona aleatoriamente según el diseño muestral.

3 Propiedades de los estimadores

3.1 Esperanza matemática

Sea $\hat{T}$ un estimador de θ. Su esperanza matemática es

$$E[\hat{T}] = \sum_i t_i P(\hat{T} = t_i).$$

3.2 Insesgadez

Se dice que $\hat{T}$ es **insesgado** para θ si

$$E[\hat{T}] = \theta.$$

Esto significa que, en promedio, el estimador acierta el verdadero valor del parámetro.

3.3 Sesgo

Si $E[\hat{T}] \neq \theta$, entonces el estimador es **sesgado**. El sesgo se define como

$$B(\hat{T}) = E[\hat{T}] - \theta.$$

Y el sesgo relativo es

$$RB(\hat{T}) = \frac{B(\hat{T})}{\theta}.$$

Interpretación:

- si $B(\hat{T}) > 0$, el estimador tiende a **sobreestimar**;
- si $B(\hat{T}) < 0$, tiende a **infraestimar**.

3.4 Varianza

La varianza del estimador es

$$V(\hat{T}) = E(\hat{T}^2) - \big(E(\hat{T})\big)^2.$$

Un buen estimador no solo debería estar centrado en el parámetro, sino también presentar **poca dispersión**.

3.5 Idea de compromiso

En la práctica, buscamos estimadores que:

1. estén centrados o casi centrados en el parámetro;
2. tengan varianza pequeña;
3. sean sencillos de calcular e interpretar.

4 Determinación de estimadores lineales insesgados

En muchos problemas de muestreo, conviene buscar estimadores de la forma

$$\hat{T} = \sum_{i=1}^{n} \alpha_i w_i,$$

donde w_i son los valores muestrales asociados al parámetro que queremos estimar y los coeficientes α_i son los **pesos** o **factores de elevación**.

Esta forma lineal es muy importante porque permite construir estimadores insesgados tanto con como sin reposición.

4.1 Forma de los parámetros del curso

Los parámetros que interesan pueden escribirse en general como

$$\theta = \sum_{i=1}^{N} W_i.$$

Por ejemplo:

- para el **total poblacional**, $W_i = X_i$;
- para la **media poblacional**, $W_i = X_i/N$;
- para la **proporción**, $W_i = \delta_{u_i}/N$.

Por eso tiene sentido buscar estimadores lineales en los valores muestrales w_i.

5 Estimador de Hansen-Hurwitz

5.1 Contexto

Se utiliza en **muestreo con reposición** y con probabilidades desiguales.

El estimador lineal insesgado óptimo para el parámetro θ es

$$\hat{T}_{HH} = \sum_{i=1}^{n} \frac{1}{np_i} w_i = \frac{1}{n} \sum_{i=1}^{n} \frac{w_i}{p_i},$$

donde p_i es la probabilidad de seleccionar la unidad u_i en cada extracción.

5.2 Varianza y su estimación

La varianza viene dada por

$$V(\hat{T}_{HH}) = \frac{1}{N} \sum_{i=1}^{N} \sum_{j>i}^{N} \left(\frac{W_i}{p_i} - \frac{W_j}{p_j} \right)^2 p_i p_j,$$

y una estimación de la varianza mediante

$$\widehat{V}(\hat{T}_{HH}) = \frac{1}{n(n-1)} \sum_{i=1}^{n} \left(\frac{w_i}{p_i} - \hat{T}_{HH} \right)^2.$$

> Observación: para resolver ejercicios prácticos, normalmente se utiliza la expresión estimada de la varianza, porque solo disponemos de la muestra.

5.3 Ejercicio 1

Enunciado. Una muestra con reemplazamiento de tamaño $n = 3$ y probabilidades desiguales se obtiene de una población. Los valores observados y sus probabilidades son:

$$x_1 = 3, \quad p_1 = 0.06, \qquad x_2 = 10, \quad p_2 = 0.20, \qquad x_3 = 7, \quad p_3 = 0.10.$$

Se pide:

a) Estimar el total poblacional utilizando el estimador de Hansen-Hurwitz.

b) Estimar la varianza del estimador.

5.3.1 Paso 1. Escribir la fórmula correcta

Como el muestreo es **con reposición**, usamos

$$\hat{T}_{HH} = \frac{1}{n} \sum_{i=1}^{n} \frac{x_i}{p_i}.$$

5.3.2 Paso 2. Sustituir los datos

Calculamos cada cociente:

$$\frac{x_1}{p_1} = \frac{3}{0.06} = 50,$$
$$\frac{x_2}{p_2} = \frac{10}{0.20} = 50,$$
$$\frac{x_3}{p_3} = \frac{7}{0.10} = 70.$$

Entonces,

$$\hat{T}_{HH} = \frac{1}{3}(50 + 50 + 70) = \frac{170}{3} = 56.67.$$

5.3.3 Resultado del apartado a)

$$\boxed{\hat{T}_{HH} = 56.67}$$

5.3.4 Paso 3. Estimar la varianza

Usamos

$$\widehat{V}(\hat{T}_{HH}) = \frac{1}{n(n-1)} \sum_{i=1}^{n} \left(\frac{x_i}{p_i} - \hat{T}_{HH} \right)^2.$$

Como $n = 3$,

$$\frac{1}{n(n-1)} = \frac{1}{3 \cdot 2} = \frac{1}{6}.$$

Calculamos las desviaciones respecto de $\hat{T}_{HH} = 56.67$:

$$50 - 56.67 = -6.67,$$

$$50 - 56.67 = -6.67,$$
$$70 - 56.67 = 13.33.$$

Elevando al cuadrado:

$$(-6.67)^2 \approx 44.49,$$
$$(-6.67)^2 \approx 44.49,$$
$$(13.33)^2 \approx 177.69.$$

Sumamos:

$$44.49 + 44.49 + 177.69 = 266.67.$$

Por tanto,

$$\widehat{V}(\hat{T}_{HH}) = \frac{266.67}{6} = 44.45.$$

5.3.5 Resultado del apartado b)

$$\boxed{\widehat{V}(\hat{T}_{HH}) \approx 44.45}$$

La estimación puntual del total es 56.67. La varianza estimada mide la dispersión que tendría este estimador bajo repetición del muestreo con el mismo diseño.

5.3.6 Código en R para el Ejercicio 1

```r
# Datos
x <- c(3, 10, 7)
p <- c(0.06, 0.20, 0.10)
n <- length(x)

# Estimador de Hansen-Hurwitz
T_HH <- mean(x / p)
T_HH
```

```
## [1] 56.66667
```

```r
# Varianza estimada
V_T_HH <- sum((x / p - T_HH)^2) / (n * (n - 1))
V_T_HH
```

```
## [1] 44.44444
```

```r
# Resumen
list(
  cocientes = x / p,
  estimador_HH = T_HH,
  varianza_estimada = V_T_HH
)
```

```
## $cocientes
## [1] 50 50 70
##
## $estimador_HH
## [1] 56.66667
##
## $varianza_estimada
## [1] 44.44444
```

6 Estimador de Horvitz-Thompson

6.1 Contexto

Se utiliza en **muestreo sin reposición**.

El estimador de Horvitz-Thompson viene dado por

$$\hat{T}_{HT} = \sum_{i=1}^{n} \frac{w_i}{\pi_i},$$

donde π_i es la probabilidad de inclusión de la unidad i en la muestra.

6.2 Varianza y estimación

Para la varianza, tenemos la siguiente expresión

$$V(\hat{T}_{HT}) = \sum_{i=1}^{N} \frac{W_i^2}{\pi_i}(1-\pi_i) + 2\sum_{i=1}^{N}\sum_{j>i}^{N} \frac{W_i}{\pi_i}\frac{W_j}{\pi_j}(\pi_{ij} - \pi_i\pi_j),$$

y su estimación:

$$\widehat{V}(\hat{T}_{HT}) = \sum_{i=1}^{n} \frac{w_i^2}{\pi_i^2}(1-\pi_i) + 2\sum_{i=1}^{n}\sum_{j>i}^{n} \frac{w_i}{\pi_i}\frac{w_j}{\pi_j}\left(\frac{\pi_{ij} - \pi_i\pi_j}{\pi_{ij}}\right).$$

En el caso de probabilidades desiguales, debemos considerar que

$$\pi_i = 1 - (1-p_i)^n,$$

y

$$\pi_{ij} = \pi_i + \pi_j - \left[1 - (1-p_i-p_j)^n\right].$$

6.3 Ejercicio 2

Enunciado. Una muestra sin reemplazamiento de tamaño $n = 3$ y probabilidades desiguales proporciona:

$$x_1 = 3, \quad p_1 = 0.06, \qquad x_2 = 10, \quad p_2 = 0.20, \qquad x_3 = 7, \quad p_3 = 0.10.$$

Se pide:

a) Estimar el total poblacional mediante Horvitz-Thompson.

b) Estimar su varianza.

6.3.1 Paso 1. Calcular las probabilidades de inclusión π_i

Usamos

$$\pi_i = 1 - (1 - p_i)^n, \qquad n = 3.$$

Para la unidad 1:

$$\pi_1 = 1 - (1 - 0.06)^3 = 1 - 0.94^3 = 1 - 0.830584 = 0.169416.$$

Para la unidad 2:

$$\pi_2 = 1 - (1 - 0.20)^3 = 1 - 0.8^3 = 1 - 0.512 = 0.488.$$

Para la unidad 3:

$$\pi_3 = 1 - (1 - 0.10)^3 = 1 - 0.9^3 = 1 - 0.729 = 0.271.$$

6.3.2 Paso 2. Aplicar el estimador de Horvitz-Thompson

$$\hat{T}_{HT} = \frac{x_1}{\pi_1} + \frac{x_2}{\pi_2} + \frac{x_3}{\pi_3}.$$

Calculamos:

$$\frac{3}{0.169416} \approx 17.71,$$
$$\frac{10}{0.488} \approx 20.49,$$
$$\frac{7}{0.271} \approx 25.83.$$

Entonces,

$$\hat{T}_{HT} \approx 17.71 + 20.49 + 25.83 = 64.03.$$

6.3.3 Resultado del apartado a)

$$\boxed{\hat{T}_{HT} \approx 64.03}$$

6.3.4 Paso 3. Calcular las probabilidades dobles π_{ij}

Usamos

$$\pi_{ij} = \pi_i + \pi_j - \left[1 - (1 - p_i - p_j)^3\right].$$

6.3.4.1 Para $(1, 2)$

$$1 - p_1 - p_2 = 1 - 0.06 - 0.20 = 0.74,$$
$$1 - 0.74^3 = 1 - 0.405224 = 0.594776,$$
$$\pi_{12} = 0.169416 + 0.488 - 0.594776 = 0.062640.$$

6.3.4.2 Para $(1, 3)$

$$1 - p_1 - p_3 = 1 - 0.06 - 0.10 = 0.84,$$
$$1 - 0.84^3 = 1 - 0.592704 = 0.407296,$$
$$\pi_{13} = 0.169416 + 0.271 - 0.407296 = 0.033120.$$

6.3.4.3 Para $(2,3)$

$$1 - p_2 - p_3 = 1 - 0.20 - 0.10 = 0.70,$$
$$1 - 0.70^3 = 1 - 0.343 = 0.657,$$
$$\pi_{23} = 0.488 + 0.271 - 0.657 = 0.102.$$

6.3.5 Paso 4. Calcular la parte individual de la varianza estimada

La primera suma es

$$\sum_{i=1}^{n} \frac{x_i^2}{\pi_i^2}(1 - \pi_i).$$

Calculamos término a término:

$$\frac{3^2}{0.169416^2}(1 - 0.169416) \approx 260.37,$$
$$\frac{10^2}{0.488^2}(1 - 0.488) \approx 215.10,$$
$$\frac{7^2}{0.271^2}(1 - 0.271) \approx 486.58.$$

Suma parcial:

$$260.37 + 215.10 + 486.58 = 962.05.$$

6.3.6 Paso 5. Calcular la parte cruzada

Ahora calculamos

$$2\sum_{i=1}^{n}\sum_{j>i}^{n} \frac{x_i}{\pi_i}\frac{x_j}{\pi_j}\left(\frac{\pi_{ij} - \pi_i\pi_j}{\pi_{ij}}\right).$$

6.3.6.1 Par $(1,2)$

$$\frac{x_1}{\pi_1}\frac{x_2}{\pi_2} \approx 17.71 \cdot 20.49 = 362.80.$$

Además,

$$\pi_1\pi_2 \approx 0.169416 \cdot 0.488 = 0.082675,$$
$$\frac{\pi_{12} - \pi_1\pi_2}{\pi_{12}} = \frac{0.062640 - 0.082675}{0.062640} \approx -0.3198.$$

Por tanto, el término correspondiente es

$$2 \cdot 362.80 \cdot (-0.3198) \approx -232.05.$$

6.3.6.2 Par $(1,3)$

$$\frac{x_1}{\pi_1}\frac{x_3}{\pi_3} \approx 17.71 \cdot 25.83 = 457.57,$$
$$\pi_1\pi_3 \approx 0.169416 \cdot 0.271 = 0.045912,$$
$$\frac{\pi_{13} - \pi_1\pi_3}{\pi_{13}} = \frac{0.033120 - 0.045912}{0.033120} \approx -0.3862.$$

Término:

$$2 \cdot 457.57 \cdot (-0.3862) \approx -353.37.$$

6.3.6.3 Par $(2,3)$

$$\frac{x_2}{\pi_2}\frac{x_3}{\pi_3} \approx 20.49 \cdot 25.83 = 529.09,$$

$$\pi_2\pi_3 \approx 0.488 \cdot 0.271 = 0.132248,$$

$$\frac{\pi_{23} - \pi_2\pi_3}{\pi_{23}} = \frac{0.102 - 0.132248}{0.102} \approx -0.2965.$$

Término:

$$2 \cdot 529.09 \cdot (-0.2965) \approx -313.76.$$

La suma cruzada vale aproximadamente

$$-232.05 - 353.37 - 313.76 = -899.18.$$

6.3.7 Paso 6. Obtener la estimación final de la varianza

$$\widehat{V}(\hat{T}_{HT}) \approx 962.05 - 899.18 = 62.87.$$

6.3.8 Resultado del apartado b)

$$\boxed{\widehat{V}(\hat{T}_{HT}) \approx 62.87}$$

6.3.9 Interpretación

Horvitz-Thompson corrige el hecho de que las unidades no tienen la misma probabilidad de inclusión. La idea básica es elevar más los valores observados de unidades con menor probabilidad de entrar en la muestra.

6.3.10 Código en R para el Ejercicio 2

```r
# Datos
x <- c(3, 10, 7)
p <- c(0.06, 0.20, 0.10)
n <- length(x)

# Probabilidades de inclusión
pii <- 1 - (1 - p)^n
pii
```

```
## [1] 0.169416 0.488000 0.271000
```

```r
# Probabilidades de inclusión doble
pi12 <- pii[1] + pii[2] - (1 - (1 - p[1] - p[2])^n)
pi13 <- pii[1] + pii[3] - (1 - (1 - p[1] - p[3])^n)
pi23 <- pii[2] + pii[3] - (1 - (1 - p[2] - p[3])^n)
pij <- matrix(c(NA, pi12, pi13,
                pi12, NA, pi23,
                pi13, pi23, NA), nrow = 3, byrow = TRUE)
pij
```

```
##         [,1]    [,2]    [,3]
## [1,]      NA 0.06264 0.03312
## [2,] 0.06264      NA 0.10200
## [3,] 0.03312 0.10200      NA
```

```r
# Estimador de Horvitz-Thompson
T_HT <- sum(x / pii)
T_HT
```

```
## [1] 64.02995
```

```r
# Primera parte de la varianza estimada
parte1 <- sum((x^2 / pii^2) * (1 - pii))

# Segunda parte de la varianza estimada
parte2_12 <- 2 * (x[1] / pii[1]) * (x[2] / pii[2]) * ((pi12 - pii[1] * pii[2]) / pi12)
parte2_13 <- 2 * (x[1] / pii[1]) * (x[3] / pii[3]) * ((pi13 - pii[1] * pii[3]) / pi13)
parte2_23 <- 2 * (x[2] / pii[2]) * (x[3] / pii[3]) * ((pi23 - pii[2] * pii[3]) / pi23)
parte2 <- parte2_12 + parte2_13 + parte2_23

V_T_HT <- parte1 + parte2
V_T_HT
```

```
## [1] 62.4619
```

```r
# Resumen
list(
  probabilidades_inclusion = pii,
  probabilidades_dobles = c(pi12 = pi12, pi13 = pi13, pi23 = pi23),
  estimador_HT = T_HT,
  parte1_varianza = parte1,
  parte2_varianza = parte2,
  varianza_estimada = V_T_HT
)
```

```
## $probabilidades_inclusion
## [1] 0.169416 0.488000 0.271000
##
## $probabilidades_dobles
##    pi12    pi13    pi23
## 0.06264 0.03312 0.10200
##
## $estimador_HT
## [1] 64.02995
##
## $parte1_varianza
## [1] 961.8321
##
## $parte2_varianza
## [1] -899.3702
##
## $varianza_estimada
## [1] 62.4619
```

7 Estimación indirecta

7.1 Motivación

A veces queremos estimar características de una variable de interés Y, pero además disponemos de información auxiliar sobre otra variable X muy relacionada con Y.

Si X está **altamente correlada** con Y, esta información auxiliar puede utilizarse para **reducir el error de estimación**.

Las dos técnicas destacadas en la presentación son:

- **estimadores de razón**;
- **estimadores de regresión**.

En este documento nos centraremos sobre todo en los **estimadores de razón**.

7.2 Supuestos del tema

Supondremos:

- una muestra aleatoria simple sin reemplazamiento;
- tamaño muestral n;
- observaciones por pares (x_i, y_i);
- conocida la media poblacional de la variable auxiliar, $\bar{X}$.

8 Estimadores de razón

8.1 Idea intuitiva

Si Y y X están fuertemente relacionadas y la relación pasa aproximadamente por el origen, es razonable pensar que

$$Y \approx RX,$$

donde R representa la **razón poblacional** entre ambas variables.

Entonces podemos estimar R con la muestra y, a partir de ahí, estimar la media o el total de Y.

8.2 Definiciones fundamentales

8.2.1 Razón poblacional

$$R = \frac{\bar{Y}}{\bar{X}}.$$

8.2.2 Estimador de la razón

$$\hat{R} = \frac{\hat{\bar{Y}}}{\hat{\bar{X}}} = \frac{\bar{y}}{\bar{x}}.$$

En m.a.s. sin reemplazamiento, las medias muestrales se usan como estimadores de las medias poblacionales.

8.2.3 Estimador de la media de Y

$$\hat{\bar{Y}}_R = \hat{R}\,\bar{X}.$$

8.2.4 Estimador del total de Y

$$\hat{Y}_R = N\hat{\bar{Y}}_R.$$

8.3 Varianza aproximada

Para la varianza aproximada, se tiene la siguiente expresión

$$V(\hat{R}) = \frac{1-f}{n\bar{X}^2}\left(S_Y^2 + R^2 S_X^2 - 2RS_{XY}\right),$$

donde

$$f = \frac{n}{N}.$$

Y la estimación sesgada de esa varianza es

$$\widehat{V}(\hat{R}) = \frac{1-f}{n\bar{x}^2}\left(s_Y^2 + \hat{R}^2 s_X^2 - 2\hat{R}s_{XY}\right).$$

Además,

$$V(\hat{\bar{Y}}_R) = \bar{X}^2 V(\hat{R}),$$

y

$$V(\hat{Y}_R) = N^2 V(\hat{\bar{Y}}_R).$$

8.4 Sesgo del estimador de razón

El sesgo del estimador de razón viene dado por

$$B(\hat{R}) = \frac{1-f}{n\bar{X}^2}\left(RS_Y^2 - S_{XY}\right),$$

y su aproximación muestral es

$$\widehat{B}(\hat{R}) = \frac{1-f}{n\bar{x}^2}\left(\hat{R}s_Y^2 - s_{XY}\right).$$

El sesgo aproximado de la media estimada por razón es

$$\widehat{B}(\hat{\bar{Y}}_R) = \bar{X}\,\widehat{B}(\hat{R}),$$

y para el total,

$$\widehat{B}(\hat{Y}_R) = N\widehat{B}(\hat{\bar{Y}}_R).$$

8.5 Expresiones auxiliares

Adicionalmente, consideraremos las siguientes expresiones auxiliares:

$$1 - f = \frac{N-n}{N},$$
$$s_X^2 = \frac{1}{n-1}\left(\sum_{i=1}^{n} x_i^2 - n\bar{x}^2\right),$$
$$s_Y^2 = \frac{1}{n-1}\left(\sum_{i=1}^{n} y_i^2 - n\bar{y}^2\right),$$
$$s_{XY} = \frac{1}{n-1}\left(\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}\right).$$

9 Ejercicio 3: estimador de razón

Enunciado. Consideramos una población de $N = 500$ individuos en la que la característica bidimensional (X_i, Y_i) mide las ganancias mensuales, en miles de euros, de varones (X) y mujeres (Y) con título universitario superior. Una muestra aleatoria simple de tamaño $n = 80$ proporciona:

$$\sum_{i=1}^{80} x_i = 420, \qquad \sum_{i=1}^{80} x_i^2 = 2284,$$
$$\sum_{i=1}^{80} y_i = 190, \qquad \sum_{i=1}^{80} y_i^2 = 512,$$
$$\sum_{i=1}^{80} x_i y_i = 1045.$$

Se pide estimar la razón de las ganancias mensuales femeninas respecto de las masculinas, su sesgo y su error de muestreo, y estudiar la posible influencia del sesgo.

9.1 Paso 1. Calcular las medias muestrales

$$\bar{x} = \frac{420}{80} = 5.25,$$
$$\bar{y} = \frac{190}{80} = 2.375.$$

Por tanto,

$$\hat{R} = \frac{\bar{y}}{\bar{x}} = \frac{2.375}{5.25} = 0.45238.$$

9.1.1 Resultado principal

$$\boxed{\hat{R} \approx 0.4524}$$

Interpretación: las ganancias femeninas medias estimadas representan aproximadamente el **45.24%** de las masculinas.

9.2 Paso 2. Calcular la fracción de muestreo

$$f = \frac{n}{N} = \frac{80}{500} = 0.16,$$

por lo que

$$1 - f = 0.84.$$

9.3 Paso 3. Calcular s_X^2

Usamos

$$s_X^2 = \frac{1}{n-1}\left(\sum x_i^2 - n\bar{x}^2\right).$$

Sustituimos:

$$s_X^2 = \frac{1}{79}\left(2284 - 80 \cdot 5.25^2\right).$$

Como

$$5.25^2 = 27.5625,$$
$$80 \cdot 27.5625 = 2205,$$

obtenemos

$$s_X^2 = \frac{2284 - 2205}{79} = \frac{79}{79} = 1.$$

9.4 Paso 4. Calcular s_Y^2

$$s_Y^2 = \frac{1}{79}\left(512 - 80 \cdot 2.375^2\right).$$

Como

$$2.375^2 = 5.640625,$$
$$80 \cdot 5.640625 = 451.25,$$

queda

$$s_Y^2 = \frac{512 - 451.25}{79} = \frac{60.75}{79} = 0.76899.$$

9.5 Paso 5. Calcular s_{XY}

Para calcular s_{XY} utilizamos:

$$s_{XY} = \frac{1}{n-1}\left(\sum x_i y_i - n\bar{x}\bar{y}\right).$$

Entonces:

$$s_{XY} = \frac{1}{79}(1045 - 80 \cdot 5.25 \cdot 2.375).$$

Calculamos:

$$\frac{1045}{79} = 13.2278,$$
$$80 \cdot 5.25 \cdot 2.375 = 997.5,$$

$$\frac{997.5}{79} = 12.6266.$$

Luego,

$$s_{XY} = 13.2278 - 12.6266 = 0.6012.$$

9.6 Paso 6. Estimar la varianza de $\hat{R}$

Utilizamos la siguiente expresión:

$$\widehat{V}(\hat{R}) = \frac{1-f}{n\bar{x}^2}\left(s_Y^2 + \hat{R}^2 s_X^2 - 2\hat{R}s_{XY}\right).$$

y calculamos cada parte.

Primero,

$$\hat{R}^2 \approx 0.45238^2 = 0.20465.$$

Después,

$$2\hat{R}s_{XY} = 2 \cdot 0.45238 \cdot 0.6012 \approx 0.54394.$$

Por tanto,

$$s_Y^2 + \hat{R}^2 s_X^2 - 2\hat{R}s_{XY} \approx 0.76899 + 0.20465 - 0.54394 = 0.42970.$$

Además,

$$\bar{x}^2 = 5.25^2 = 27.5625,$$
$$n\bar{x}^2 = 80 \cdot 27.5625 = 2205.$$

Luego,

$$\widehat{V}(\hat{R}) = \frac{0.84}{2205} \cdot 0.42970 \approx 0.0001637.$$

9.6.1 Resultado

$$\boxed{\widehat{V}(\hat{R}) \approx 0.0001637}$$

9.7 Paso 7. Calcular el error de muestreo

Tomamos como error de muestreo la desviación típica estimada:

$$\hat{e}(\hat{R}) = \sqrt{\widehat{V}(\hat{R})}.$$

Así,

$$\hat{e}(\hat{R}) = \sqrt{0.0001637} \approx 0.01279.$$

9.7.1 Resultado

$$\boxed{\hat{e}(\hat{R}) \approx 0.01279}$$

9.8 Paso 8. Aproximar el sesgo

Usamos

$$\widehat{B}(\hat{R}) = \frac{1-f}{n\bar{x}^2}\left(\hat{R}s_Y^2 - s_{XY}\right).$$

Calculamos:

$$\hat{R}s_Y^2 \approx 0.45238 \cdot 0.76899 = 0.34783.$$

Por tanto,

$$\hat{R}s_Y^2 - s_{XY} = 0.34783 - 0.6012 = -0.25337.$$

Entonces,

$$\widehat{B}(\hat{R}) = \frac{0.84}{2205}(-0.25337) \approx -0.0000965.$$

9.8.1 Resultado

$$\boxed{\widehat{B}(\hat{R}) \approx -0.0000965}$$

9.9 Paso 9. Estudiar la influencia del sesgo

Comparamos la magnitud del sesgo con el error de muestreo:

$$|\widehat{B}(\hat{R})| \approx 0.0000965, \qquad \hat{e}(\hat{R}) \approx 0.01279.$$

Se observa que

$$|\widehat{B}(\hat{R})| \ll \hat{e}(\hat{R}).$$

9.9.1 Conclusión

El sesgo estimado es **muy pequeño** frente al error de muestreo, por lo que **su influencia práctica es despreciable** en este caso.

9.9.2 Código en R para el Ejercicio 3

```r
# Datos
N <- 500
n <- 80
sum_x <- 420
sum_x2 <- 2284
sum_y <- 190
sum_y2 <- 512
sum_xy <- 1045

# Medias muestrales
x_bar <- sum_x / n
y_bar <- sum_y / n
R_hat <- y_bar / x_bar
```

```r
# Fracción de muestreo
f <- n / N

# Cuasivarianzas y covarianza
s2_x <- (sum_x2 - n * x_bar^2) / (n - 1)
s2_y <- (sum_y2 - n * y_bar^2) / (n - 1)
s_xy <- (sum_xy - n* x_bar * y_bar) / (n - 1)

# Varianza estimada de R_hat
V_R_hat <- ((1 - f) / (n * x_bar^2)) * (s2_y + R_hat^2 * s2_x - 2 * R_hat * s_xy)

# Error de muestreo
error_R_hat <- sqrt(V_R_hat)

# Sesgo aproximado
B_R_hat <- ((1 - f) / (n * x_bar^2)) * (R_hat * s2_y - s_xy)

# Resumen
list(
  x_bar = x_bar,
  y_bar = y_bar,
  R_hat = R_hat,
  s2_x = s2_x,
  s2_y = s2_y,
  s_xy = s_xy,
  V_R_hat = V_R_hat,
  error_R_hat = error_R_hat,
  B_R_hat = B_R_hat,
  sesgo_relevante = abs(B_R_hat) > error_R_hat
)
```

```
## $x_bar
## [1] 5.25
##
## $y_bar
## [1] 2.375
##
## $R_hat
## [1] 0.452381
##
## $s2_x
## [1] 1
##
## $s2_y
## [1] 0.7689873
##
## $s_xy
## [1] 0.6012658
##
## $V_R_hat
## [1] 0.0001636699
##
## $error_R_hat
```

```
## [1] 0.01279335
##
## $B_R_hat
## [1] -9.652975e-05
##
## $sesgo_relevante
## [1] FALSE
```

10 Ejercicio propuesto guiado

10.1 Enunciado

En una población de tamaño $N = 300$ se selecciona una muestra aleatoria simple sin reemplazamiento de tamaño $n = 60$. Para una variable auxiliar X y una variable de interés Y se obtienen:

$$\sum_{i=1}^{60} x_i = 240, \qquad \sum_{i=1}^{60} x_i^2 = 1020,$$

$$\sum_{i=1}^{60} y_i = 150, \qquad \sum_{i=1}^{60} y_i^2 = 510,$$

$$\sum_{i=1}^{60} x_i y_i = 680.$$

Se pide:

1. Estimar la razón poblacional R.
2. Estimar su varianza.
3. Aproximar su sesgo.
4. Comentar si el sesgo parece relevante.

10.2 Sugerencias para resolverlo

1. Calcula primero $\bar{x}$ y $\bar{y}$.
2. Usa $\hat{R} = \bar{y}/\bar{x}$.
3. Calcula s_X^2, s_Y^2 y s_{XY}.
4. Sustituye en las fórmulas de $\widehat{V}(\hat{R})$ y $\widehat{B}(\hat{R})$.
5. Compara $|\widehat{B}(\hat{R})|$ con $\sqrt{\widehat{V}(\hat{R})}$.

10.3 Solución resumida

10.3.1 Paso 1. Medias

$$\bar{x} = \frac{240}{60} = 4, \qquad \bar{y} = \frac{150}{60} = 2.5.$$

Luego,

$$\hat{R} = \frac{2.5}{4} = 0.625.$$

10.3.2 Paso 2. Fracción de muestreo

$$f = \frac{60}{300} = 0.2, \qquad 1 - f = 0.8.$$

10.3.3 Paso 3. Cuasivarianzas y covarianza

$$s_X^2 = \frac{1}{59}(1020 - 60 \cdot 4^2) = \frac{60}{59} \approx 1.01695.$$

$$s_Y^2 = \frac{1}{59}(510 - 60 \cdot 2.5^2) = \frac{135}{59} \approx 2.28814.$$

$$s_{XY} = \frac{1}{59}(680 - 60 \cdot 4 \cdot 2.5) = \frac{1}{59} \cdot 80 = 1.3559.$$

10.3.4 Paso 4. Varianza estimada

$$\widehat{V}(\hat{R}) = \frac{0.8}{60 \cdot 4^2}\left(2.28814 + 0.625^2 \cdot 1.01695 - 2 \cdot 0.625 \cdot 1.3559\right).$$

Como

$$0.625^2 \cdot 1.01695 \approx 0.39725,$$
$$2 \cdot 0.625 \cdot 1.3559 \approx 1.69488,$$

queda

$$\widehat{V}(\hat{R}) \approx \frac{0.8}{960}(0.9905) \approx 0.000825.$$

Entonces,

$$\hat{e}(\hat{R}) = \sqrt{0.000825} \approx 0.0287.$$

10.3.5 Paso 5. Sesgo aproximado

$$\widehat{B}(\hat{R}) = \frac{0.8}{960}(0.625 \cdot 2.28814 - 1.3559).$$

Como

$$0.625 \cdot 2.28814 \approx 1.43009,$$

obtenemos

$$\widehat{B}(\hat{R}) \approx \frac{0.8}{960}(0.07419) \approx 0.0000618.$$

10.3.6 Conclusión

$$|\widehat{B}(\hat{R})| \approx 0.0000618 \ll 0.0287 \approx \hat{e}(\hat{R}).$$

Por tanto, el sesgo vuelve a ser **irrelevante en términos prácticos**.

10.3.7 Código en R para el ejercicio propuesto guiado

```r
# Datos
N <- 300
n <- 60
sum_x <- 240
sum_x2 <- 1020
sum_y <- 150
sum_y2 <- 510
sum_xy <- 680

# Medias
x_bar <- sum_x / n
y_bar <- sum_y / n
R_hat <- y_bar / x_bar

# Fracción de muestreo
f <- n / N

# Cuasivarianzas y covarianza
s2_x <- (sum_x2 - n * x_bar^2) / (n - 1)
s2_y <- (sum_y2 - n * y_bar^2) / (n - 1)
s_xy <- (sum_xy - n * x_bar * y_bar) / (n - 1)

# Varianza estimada
V_R_hat <- ((1 - f) / (n * x_bar^2)) * (s2_y + R_hat^2 * s2_x - 2 * R_hat * s_xy)
error_R_hat <- sqrt(V_R_hat)

# Sesgo aproximado
B_R_hat <- ((1 - f) / (n * x_bar^2)) * (R_hat * s2_y - s_xy)

# Resumen
list(
  x_bar = x_bar,
  y_bar = y_bar,
  R_hat = R_hat,
  s2_x = s2_x,
  s2_y = s2_y,
  s_xy = s_xy,
  V_R_hat = V_R_hat,
  error_R_hat = error_R_hat,
  B_R_hat = B_R_hat,
  sesgo_relevante = abs(B_R_hat) > error_R_hat
)
```

```
## $x_bar
```

```
## [1] 4
##
## $y_bar
## [1] 2.5
##
## $R_hat
## [1] 0.625
##
## $s2_x
## [1] 1.016949
##
## $s2_y
## [1] 2.288136
##
## $s_xy
## [1] 1.355932
##
## $V_R_hat
## [1] 0.0008253884
##
## $error_R_hat
## [1] 0.02872957
##
## $B_R_hat
## [1] 6.179379e-05
##
## $sesgo_relevante
## [1] FALSE
```