Muestreo por conglomerados

Alicia Irusta Tejedor

2026-04-24

Resumen teórico

Idea básica

En el muestreo por conglomerados, las unidades de muestreo no son las unidades elementales, sino grupos de unidades llamados **conglomerados**. La idea es seleccionar conglomerados y, según el diseño, observar:

- todos los elementos del conglomerado seleccionado (**una etapa**), o
- solo una submuestra dentro de cada conglomerado seleccionado (**dos etapas**).

Este diseño resulta especialmente útil cuando:

- no se dispone de un marco completo de unidades elementales,
- la población está naturalmente agrupada,
- interesa reducir costes de desplazamiento y trabajo de campo.

Muestreo por conglomerados en una etapa

Caso de conglomerados del mismo tamaño

Si todos los conglomerados tienen el mismo tamaño $\bar{M}$, la estimación de la media poblacional es

$$\hat{\bar{X}}_{MC} = \bar{\bar{x}} = \frac{1}{n}\sum_{i=1}^{n} \bar{x}_i.$$

La estimación de su varianza es

$$\widehat{V}(\hat{\bar{X}}_{MC}) = \frac{(1-f)s_b^2}{n\bar{M}},$$

siendo

$$s_b^2 = \frac{\sum_{i=1}^{n} \bar{M}(\bar{x}_i - \bar{\bar{x}})^2}{n-1}.$$

Caso de conglomerados de distinto tamaño

Si los conglomerados tienen tamaños distintos y M es conocido, el estimador de la media poblacional es

$$\hat{\bar{X}}_{MC} = \frac{1}{n}\sum_{i=1}^{n}\frac{x_i}{M_i} = \frac{1}{n}\sum_{i=1}^{n}\bar{x}_i.$$

Su estimación de varianza, siguiendo la expresión de la presentación, es

$$\widehat{V}(\hat{\bar{X}}_{MC}) = \frac{1-f}{n(n-1)\bar{M}^2}\sum_{i=1}^{n}M_i^2(\bar{x}_i - \hat{\bar{X}}_{MC})^2.$$

Si queremos estimar el total poblacional, usamos

$$\hat{X}_{MC} = M\hat{\bar{X}}_{MC},$$

y entonces

$$\widehat{V}(\hat{X}_{MC}) = M^2\widehat{V}(\hat{\bar{X}}_{MC}).$$

Ejercicio 1

Enunciado

En una ciudad universitaria se quiere estimar el **número medio de dispositivos electrónicos por hogar** mediante **muestreo por conglomerados en una etapa**. La ciudad está dividida en $N = 240$ bloques, cada uno con $\bar{M} = 10$ hogares, de modo que la población total es $M = 2400$ hogares.

Se selecciona una muestra aleatoria simple de $n = 6$ bloques y se entrevista a **todos** los hogares de cada bloque seleccionado. Los datos obtenidos son:

Bloque	Valores observados en los 10 hogares	Total X_i	Media $\bar{x}_i$
1	3, 2, 4, 3, 5, 4, 2, 3, 4, 2	32	3.2
2	1, 2, 2, 3, 2, 1, 2, 3, 2, 2	20	2.0
3	4, 5, 3, 4, 4, 5, 4, 3, 4, 4	40	4.0
4	2, 3, 2, 2, 3, 2, 1, 2, 3, 2	22	2.2
5	5, 4, 4, 5, 3, 4, 5, 4, 4, 5	43	4.3

Bloque	Valores observados en los 10 hogares	Total X_i	Media $\bar{x}_i$
6	3, 3, 2, 4, 3, 2, 3, 4, 3, 3	30	3.0

Se pide:

1. Estimar el número medio de dispositivos por hogar.
2. Estimar la varianza del estimador utilizado.
3. Calcular el error de muestreo estimado.

Resolución teórica paso a paso

Paso 1. Identificar el diseño

Estamos en un **muestreo por conglomerados en una etapa con conglomerados del mismo tamaño** porque:

- se seleccionan bloques completos,
- se observa a todos los hogares dentro de cada bloque,
- cada bloque tiene 10 hogares.

Por tanto, usamos:

$$\hat{\bar{X}}_{MC} = \bar{\bar{x}} = \frac{1}{n}\sum_{i=1}^{n} \bar{x}_i.$$

Paso 2. Calcular la media de las medias de conglomerado

Las medias muestrales de los conglomerados son:

$$\bar{x}_1 = 3.2, \quad \bar{x}_2 = 2.0, \quad \bar{x}_3 = 4.0,$$
$$\bar{x}_4 = 2.2, \quad \bar{x}_5 = 4.3, \quad \bar{x}_6 = 3.0.$$

Luego,

$$\hat{\bar{X}}_{MC} = \frac{3.2 + 2.0 + 4.0 + 2.2 + 4.3 + 3.0}{6} = \frac{18.7}{6} = 3.1167.$$

Por tanto, la estimación del número medio de dispositivos por hogar es

$$\boxed{\hat{\bar{X}}_{MC} = 3.1167.}$$

Paso 3. Calcular s_b^2

Para calcular s_b^2, utilizamos la siguiente expresión:

$$s_b^2 = \frac{\sum_{i=1}^{n} \bar{M}(\bar{x}_i - \bar{\bar{x}})^2}{n-1}.$$

Como $\bar{M} = 10$, $n = 6$ y $\bar{\bar{x}} = 3.1167$, calculamos:

$$\begin{aligned}\sum_{i=1}^{6} \bar{M}(\bar{x}_i - \bar{\bar{x}})^2 &= 10(3.2 - 3.1167)^2 + 10(2.0 - 3.1167)^2 + 10(4.0 - 3.1167)^2 \\ &\quad + 10(2.2 - 3.1167)^2 + 10(4.3 - 3.1167)^2 + 10(3.0 - 3.1167)^2 \\ &= 42.8833.\end{aligned}$$

Así,

$$s_b^2 = \frac{42.8833}{5} = 8.5767.$$

Paso 4. Estimar la varianza del estimador de la media

La fracción de muestreo es

$$f = \frac{n}{N} = \frac{6}{240} = 0.025.$$

Entonces,

$$\widehat{V}(\hat{\bar{X}}_{MC}) = \frac{(1-f)s_b^2}{n\bar{M}} = \frac{(1-0.025)\cdot 8.5767}{6\cdot 10}.$$

Por tanto,

$$\widehat{V}(\hat{\bar{X}}_{MC}) = 0.13937.$$

Paso 5. Error de muestreo estimado

El error de muestreo estimado es la raíz cuadrada de la varianza estimada:

$$\widehat{EE}(\hat{\bar{X}}_{MC}) = \sqrt{\widehat{V}(\hat{\bar{X}}_{MC})} = \sqrt{0.13937} = 0.3733.$$

Conclusión del ejercicio 1

Estimamos que el número medio de dispositivos electrónicos por hogar en la ciudad es aproximadamente

$$\boxed{3.12 \text{ dispositivos por hogar}}.$$

La varianza estimada del estimador es

$$\boxed{\widehat{V}(\hat{\bar{X}}_{MC}) = 0.13937},$$

y el error de muestreo estimado es

$$\boxed{\widehat{EE}(\hat{\bar{X}}_{MC}) = 0.3733}.$$

Código en R para el ejercicio 1

```r
N  <- 240
n  <- 6
Mbar <- 10
M  <- N * Mbar

bloques <- list(
  c(3, 2, 4, 3, 5, 4, 2, 3, 4, 2),
  c(1, 2, 2, 3, 2, 1, 2, 3, 2, 2),
  c(4, 5, 3, 4, 4, 5, 4, 3, 4, 4),
  c(2, 3, 2, 2, 3, 2, 1, 2, 3, 2),
  c(5, 4, 4, 5, 3, 4, 5, 4, 4, 5),
  c(3, 3, 2, 4, 3, 2, 3, 4, 3, 3)
)

Xi <- sapply(bloques, sum)
xbari <- sapply(bloques, mean)

datos15 <- data.frame(
  bloque = 1:6,
  Xi = Xi,
  xbar_i = xbari
)

datos15
```

```
#>   bloque Xi xbar_i
#> 1      1 32    3.2
```

```
#> 2      2 20    2.0
#> 3      3 40    4.0
#> 4      4 22    2.2
#> 5      5 43    4.3
#> 6      6 30    3.0
```

```r
f <- n / N
xbarbar <- mean(xbari)
sb2 <- sum(Mbar * (xbari - xbarbar)^2) / (n - 1)
Vhat_media <- (1 - f) * sb2 / (n * Mbar)
EE_media <- sqrt(Vhat_media)

list(
  estimacion_media = xbarbar,
  sb2 = sb2,
  varianza_estimada = Vhat_media,
  error_muestreo = EE_media
)
```

```
#> $estimacion_media
#> [1] 3.116667
#>
#> $sb2
#> [1] 8.576667
#>
#> $varianza_estimada
#> [1] 0.1393708
#>
#> $error_muestreo
#> [1] 0.373324
```

Muestreo por conglomerados en dos etapas

Cuando observar a todos los elementos del conglomerado resulta costoso, se seleccionan primero conglomerados y después una submuestra dentro de cada uno.

Caso de conglomerados de distinto tamaño en dos etapas

Si queremos estimar la media poblacional y el tamaño total M es conocido, utilizamos:

$$\hat{\bar{X}}_{MB} = \frac{N}{M}\frac{1}{n}\sum_{i=1}^{n} M_i \bar{x}_i.$$

La estimación de la varianza es

$$\widehat{V}(\hat{\bar{X}}_{MB}) = \frac{(1-f_1)s_{bb}^2}{n\bar{M}^2} + \frac{1}{nN\bar{M}^2}\sum_{i=1}^{n}\frac{M_i^2(M_i-m_i)s_i^2}{M_i m_i},$$

donde

$$f_1 = \frac{n}{N},$$

$$s_{bb}^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(M_i\bar{x}_i - \bar{M}\hat{\bar{X}}_{MB}\right)^2,$$

y

$$s_i^2 = \frac{1}{m_i-1}\sum_{j=1}^{m_i}(x_{ij}-\bar{x}_i)^2.$$

Ejercicio 2

Enunciado

Un ayuntamiento quiere estimar el **precio medio mensual del alquiler para estudiantes** (en euros) mediante un **muestreo por conglomerados en dos etapas de distinto tamaño**.

La población está formada por $N = 180$ edificios con pisos de estudiantes. Se sabe que el número total de pisos es $M = 5400$, luego

$$\bar{M} = \frac{M}{N} = \frac{5400}{180} = 30.$$

En una primera etapa se seleccionan $n = 5$ edificios. En una segunda etapa se eligen aleatoriamente m_i pisos dentro de cada edificio. Los datos observados son:

Edificio	M_i	m_i	$\bar{x}_i$	s_i^2
1	28	6	82	64
2	35	7	76	49
3	24	5	91	81
4	31	6	88	36
5	29	6	79	100

Se pide:

1. Estimar el precio medio mensual del alquiler.
2. Estimar la varianza del estimador utilizado.
3. Calcular el error de muestreo estimado.
4. Estimar, además, el total poblacional del gasto mensual en alquiler.

Resolución teórica paso a paso

Paso 1. Identificar el diseño

Se trata de un **muestreo por conglomerados en dos etapas de distinto tamaño**, porque:

- en la primera etapa se seleccionan edificios,
- en la segunda etapa se seleccionan algunos pisos dentro de cada edificio,
- los tamaños M_i no son todos iguales.

Como M es conocido, usamos

$$\hat{\bar{X}}_{MB} = \frac{N}{M}\frac{1}{n}\sum_{i=1}^{n} M_i \bar{x}_i.$$

Paso 2. Calcular la estimación de la media

Primero calculamos los productos $M_i\bar{x}_i$:

$$\begin{aligned} M_1\bar{x}_1 &= 28 \cdot 82 = 2296, \\ M_2\bar{x}_2 &= 35 \cdot 76 = 2660, \\ M_3\bar{x}_3 &= 24 \cdot 91 = 2184, \\ M_4\bar{x}_4 &= 31 \cdot 88 = 2728, \\ M_5\bar{x}_5 &= 29 \cdot 79 = 2291. \end{aligned}$$

La suma es

$$\sum_{i=1}^{5} M_i\bar{x}_i = 2296 + 2660 + 2184 + 2728 + 2291 = 12159.$$

Entonces,

$$\hat{\bar{X}}_{MB} = \frac{180}{5400} \cdot \frac{12159}{5}.$$

Como $180/5400 = 1/30$, obtenemos

$$\hat{\bar{X}}_{MB} = \frac{12159}{150} = 81.06.$$

Por tanto,

$$\boxed{\hat{\bar{X}}_{MB} = 81.06 \text{ euros.}}$$

Paso 3. Calcular f_1

$$f_1 = \frac{n}{N} = \frac{5}{180} = 0.02778.$$

Paso 4. Calcular s_{bb}^2

Necesitamos

$$s_{bb}^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(M_i\bar{x}_i - \bar{M}\hat{\bar{X}}_{MB}\right)^2.$$

Como $\bar{M} = 30$ y $\hat{\bar{X}}_{MB} = 81.06$,

$$\bar{M}\hat{\bar{X}}_{MB} = 30 \cdot 81.06 = 2431.8.$$

Luego,

$$\begin{aligned}
(2296 - 2431.8)^2 &= 18441.64,\\
(2660 - 2431.8)^2 &= 52075.24,\\
(2184 - 2431.8)^2 &= 61406.44,\\
(2728 - 2431.8)^2 &= 87734.44,\\
(2291 - 2431.8)^2 &= 19824.64.
\end{aligned}$$

La suma vale

$$239482.40.$$

Por tanto,

$$s_{bb}^2 = \frac{239482.40}{4} = 59870.60 \approx 59870.20.$$

(La pequeña diferencia se debe al redondeo intermedio.)

Paso 5. Calcular el segundo componente de la varianza

Ahora calculamos

$$\sum_{i=1}^{n}\frac{M_i^2(M_i - m_i)s_i^2}{M_i m_i} = \sum_{i=1}^{n}\frac{M_i(M_i - m_i)s_i^2}{m_i}.$$

Término a término:

$$\frac{28(28-6)64}{6} = 6570.67,$$

$$\frac{35(35-7)49}{7} = 6860,$$

$$\frac{24(24-5)81}{5} = 7387.20,$$

$$\frac{31(31-6)36}{6} = 4650,$$

$$\frac{29(29-6)100}{6} = 11116.67.$$

Por tanto,

$$\sum_{i=1}^{5} \frac{M_i^2(M_i - m_i)s_i^2}{M_i m_i} = 36584.50.$$

Paso 6. Estimar la varianza de $\hat{\bar{X}}_{MB}$

Usamos la fórmula completa:

$$\widehat{V}(\hat{\bar{X}}_{MB}) = \frac{(1-f_1)s_{bb}^2}{n\bar{M}^2} + \frac{1}{nN\bar{M}^2}\sum_{i=1}^{n} \frac{M_i^2(M_i - m_i)s_i^2}{M_i m_i}.$$

Sustituyendo:

$$\widehat{V}(\hat{\bar{X}}_{MB}) = \frac{(1-0.02778)\cdot 59870.20}{5\cdot 30^2} + \frac{36584.50}{5\cdot 180\cdot 30^2}.$$

Así,

$$\widehat{V}(\hat{\bar{X}}_{MB}) = 12.9801.$$

Paso 7. Error de muestreo estimado

$$\widehat{EE}(\hat{\bar{X}}_{MB}) = \sqrt{12.9801} = 3.6028.$$

Paso 8. Estimación del total poblacional

La estimación del total poblacional es

$$\hat{X}_{MB} = M\hat{\bar{X}}_{MB} = 5400 \cdot 81.06 = 437724.$$

Por tanto,

$$\boxed{\hat{X}_{MB} = 437724 \text{ euros.}}$$

Conclusión del ejercicio 2

Estimamos que el precio medio mensual del alquiler para estudiantes es

$$\boxed{81.06 \text{ euros}}.$$

La varianza estimada del estimador de la media es

$$\boxed{\hat{V}(\hat{\bar{X}}_{MB}) = 12.9801},$$

y el error de muestreo estimado es

$$\boxed{\widehat{EE}(\hat{\bar{X}}_{MB}) = 3.6028 \text{ euros.}}$$

Además, la estimación del total poblacional del gasto mensual en alquiler es

$$\boxed{\hat{X}_{MB} = 437724 \text{ euros.}}$$

Código en R para el ejercicio 2

```r
N  <- 180
M  <- 5400
Mbar <- M / N
n  <- 5

Mi  <- c(28, 35, 24, 31, 29)
mi  <- c(6, 7, 5, 6, 6)
xbari <- c(82, 76, 91, 88, 79)
si2 <- c(64, 49, 81, 36, 100)

datos16 <- data.frame(
  edificio = 1:5,
  Mi = Mi,
```

```
  mi = mi,
  xbar_i = xbari,
  si2 = si2,
  Mi_xbar_i = Mi * xbari
)

datos16
```

```
#>   edificio Mi mi xbar_i si2 Mi_xbar_i
#> 1        1 28  6     82  64      2296
#> 2        2 35  7     76  49      2660
#> 3        3 24  5     91  81      2184
#> 4        4 31  6     88  36      2728
#> 5        5 29  6     79 100      2291
```

```
f1 <- n / N

xbar_hat <- (N / M) * sum(Mi * xbari) / n
sbb2 <- sum((Mi * xbari - Mbar * xbar_hat)^2) / (n - 1)
termino2 <- sum(Mi^2 * (Mi - mi) * si2 / (Mi * mi))

Vhat_xbar <- (1 - f1) * sbb2 / (n * Mbar^2) + termino2 / (n * N * Mbar^2)
EE_xbar <- sqrt(Vhat_xbar)
Xhat_total <- M * xbar_hat

list(
  estimacion_media = xbar_hat,
  sbb2 = sbb2,
  termino_segunda_etapa = termino2,
  varianza_estimada = Vhat_xbar,
  error_muestreo = EE_xbar,
  estimacion_total = Xhat_total
)
```

```
#> $estimacion_media
#> [1] 81.06
#>
#> $sbb2
#> [1] 59870.2
#>
#> $termino_segunda_etapa
#> [1] 36584.53
#>
#> $varianza_estimada
#> [1] 12.98009
#>
```

```
#> $error_muestreo
#> [1] 3.602789
#>
#> $estimacion_total
#> [1] 437724
```